Emotion-Aware Image Captioning Pipeline - প্রযুক্তিগত সংক্ষিপ্তসার

সম্পূর্ণ Pipeline-এর ব্যাখ্যা

আমাদের emotion-aware image captioning system একটি অত্যাধুনিক encoder-decoder architecture বাস্তবায়ন করে যা Vision Transformer (ViT) এবং GPT-2 components-কে একত্রিত করে contextually সঠিক এবং emotionally সমৃদ্ধ image captions তৈরি করে। এই pipeline তিনটি স্বতন্ত্র পর্যায়ে কাজ করে: visual feature extraction, caption generation, এবং emotion-aware enhancement, যা সম্পূর্ণভাবে Flickr30k dataset-এ trained এবং evaluated হয়েছে যেখানে 31,000টি images রয়েছে এবং প্রতিটি image-এর জন্য একাধিক reference captions রয়েছে।

Architecture এবং Model Configuration

Vision encoder একটি pretrained ViT-Base model (vit_base_patch16_224) ব্যবহার করে যা TIMM library থেকে নেওয়া হয়েছে, এটি 224×224 pixel images-কে process করে সেগুলোকে 196টি non-overlapping 16×16 pixel patches-এ বিভক্ত করে। এই patches গুলোকে linearly embed করা হয় 768-dimensional vectors-এ এবং 8টি transformer encoder blocks-এর মধ্য দিয়ে process করা হয়, যেখানে প্রতিটি block-এ multi-head self-attention mechanisms রয়েছে 4টি attention heads সহ এবং তার পরে feedforward networks রয়েছে। Encoder একটি learnable [CLS] token যোগ করে patch sequence-এর শুরুতে, এবং সব 8টি encoder layers-এর মধ্য দিয়ে processing-এর পর এই [CLS] token-এর 768-dimensional representation সম্পূর্ণ image-এর global visual semantics capture করে। Encoder এবং decoder-এর মধ্যে dimensional mismatch সমাধানের জন্য, আমরা একটি linear projection layer ব্যবহার করি যা 768-dimensional ViT output-কে decoder-এর 512-dimensional input space-এ map করে।

চার

Language decoder একটি custom GPT-2 architecture বাস্তবায়ন করে যা বিশেষভাবে image captioning-এর জন্য cross-attention mechanisms-এর মাধ্যমে design করা হয়েছে। Decoder 512-dimensional embeddings নিয়ে কাজ করে এবং 50 tokens পর্যন্ত length-এর sequences process করতে পারে, GPT-2 tokenizer-এর 50,260 tokens-এর vocabulary ব্যবহার করে যার মধ্যে sequence boundaries ([BOS], [EOS]) এবং padding ([PAD])-এর জন্য special tokens রয়েছে। Decoder-এ 8টি transformer decoder blocks আছে যা পরপর stack করা, যেখানে প্রতিটি block-এ তিনটি গুরুত্বপূর্ণ components রয়েছে: causal masked self-attention যা নিশ্চিত করে প্রতিটি token শুধুমাত্র sequence-এর আগের tokens-এ attend করে, cross-attention যা text tokens-কে image encoding থেকে information query করতে দেয়, এবং একটি feedforward network যার 4× dimensional expansion (512→2048→512) রয়েছে GELU activation সহ। প্রতিটি decoder block 8টি attention heads ব্যবহার করে, যা model-কে একসাথে বিভিন্ন linguistic patterns এবং visual-textual relationships capture করতে সক্ষম করে।

তিন

Training Strategy এবং Regularization

Research paper-এর সুপারিশ অনুসরণ করে, আমরা model-টি configure করেছি aggressive regularization সহ 0.5 dropout rates দিয়ে সব layers জুড়ে—embedding dropout, attention dropout, এবং MLP dropout—যাতে তুলনামূলকভাবে ছোট Flickr30k dataset-এ overfitting প্রতিরোধ করা যায়। Training একটি two-phase strategy অনুসরণ করে: প্রথমে, pretrained ViT encoder-কে 2 epochs-এর জন্য freeze করা হয় যখন শুধুমাত্র dimension mapping layer এবং GPT decoder train করা হয় 2×10^{-4} learning rate এবং 1×10^{-6} weight decay সহ, যা decoder-কে visual features interpret করতে শিখতে দেয় encoder-এর pretrained representations disturb না করে। এরপর,

সব components একসাথে jointly fine-tuned করা হয় আরও 4 epochs-এর জন্য (মোট 6 epochs) একই learning rate দিয়ে, যা সম্পূর্ণ encoder-decoder pipeline-এর end-to-end optimization সক্ষম করে। Model images process করে 16-এর batches-এ এবং 80-20 train-test split implement করে, dataset-এর 20% rigorous evaluation-এর জন্য reserve রাখে।

DeepFace দিয়ে Emotion Detection

Base captions তৈরি করার পর, আমরা সেগুলোকে emotional context দিয়ে enhance করি DeepFace ব্যবহার করে, যা একটি state-of-the-art facial emotion recognition framework। DeepFace input image analyze করে এবং dominant facial expression-কে সাতটি emotion categories-এর একটিতে classify করে: happy, sad, angry, surprise, fear, disgust, অথবা neutral। Model টি image-কে deep convolutional networks-এর মধ্য দিয়ে process করে যা large-scale facial expression datasets-এ pretrained, প্রতিটি emotion category-র জন্য confidence scores return করে এবং সবচেয়ে বেশি score-এর emotion-কে dominant expression হিসেবে select করে। এই emotion detection caption generation process থেকে independently কাজ করে এবং enforce_detection False set করে execute হয়, যা system-কে gracefully handle করতে দেয় এমন images যেখানে detectable faces নেই, neutral emotional state default করে।

NLTK POS Tagging ব্যবহার করে Grammatical Emotion Insertion

Detected emotion শুধুমাত্র caption-এর শুরুতে যোগ করা হয় না বরং NLTK থেকে sophisticated natural language processing techniques ব্যবহার করে grammatically insert করা হয়। প্রথমে, আমরা প্রতিটি detected emotion-কে একটি উপযুক্ত descriptive adjective-এ map করি—উদাহরণস্বরূপ, 'happy' map হয় 'joyful'-এ, 'sad' map হয় 'melancholic'-এ, 'angry' থাকে 'angry', 'surprise' হয়ে যায় 'surprised', 'fear' transform হয় 'fearful'-এ, 'disgust' convert হয় 'disgusted'-এ, এবং 'neutral' translate হয় 'calm'-এ। এই mapping নিশ্চিত করে যে emotional descriptors natural এবং varied হয় repetitive-এর বদলে। এরপর, আমরা base caption-কে individual words-এ tokenize করি NLTK-এর word_tokenize function ব্যবহার করে এবং part-of-speech tagging প্রয়োগ করি averaged perceptron tagger ব্যবহার করে, যা প্রতিটি word-এ grammatical tags assign করে যেমন NN singular nouns-এর জন্য, NNS plural nouns-এর জন্য, NNP proper nouns-এর জন্য, VB verbs-এর জন্য, JJ adjectives-এর জন্য, ইত্যাদি। Algorithm তারপর tagged word sequence traverse করে প্রথম noun খোঁজে (যা 'NN' দিয়ে শুরু হওয়া tags দিয়ে identify করা হয়), এবং এই noun locate করার পর, emotion adjective সরাসরি এর আগে insert করে grammatically coherent modification তৈরি করতে। উদাহরণস্বরূপ, base caption "A dog is playing in the park" যার detected emotion 'happy' হলে এর POS tags analyze হবে [('A', 'DT'), ('dog', 'NN'), ('is', 'VBZ'), ('playing', 'VBG'), ('in', 'IN'), ('the', 'DT'), ('park', 'NN')] হিসেবে, এবং algorithm 'dog'-কে প্রথম noun (NN tag) হিসেবে identify করবে এবং 'joyful' এর আগে insert করবে, যা produce করবে "A joyful dog is playing in the park"। এই approach grammatical correctness এবং natural language flow বজায় রাখে, কারণ adjective primary subject noun-কে modify করে একটি awkward prefix হিসেবে appear করার বদলে। এমন ক্ষেত্রে যেখানে কোনো noun detect করা যায় না—যা rare কিন্তু incomplete বা fragmentary captions-এ possible—algorithm একটি fallback strategy employ করে emotion adjective প্রথম word-এর পরে insert করে যাতে কিছু না কিছু emotional enhancement ঘটে।

Comprehensive Evaluation Framework

আমরা base caption generation quality evaluate করি industry-standard metrics ব্যবহার করে: BLEU-1, BLEU-

2, BLEU-3, এবং BLEU-4, যা generated এবং reference captions-এর মধ্যে n-gram precision measure করে smoothing functions সহ zero-count n-grams handle করার জন্য, এবং METEOR, যা synonyms, stemming, এবং word order বিবেচনা করে exact matches-এর পাশাপাশি। এই metrics শুধুমাত্র base captions-এ computed হয় emotion enhancement ছাড়া, existing research-এর সাথে fair comparison নিশ্চিত করতে এবং emotion augmentation থেকে core captioning performance isolate করতে। Evaluation সম্পূর্ণ 20% test set জুড়ে run হয় যাতে প্রায় 6,000 images রয়েছে, প্রতিটি image-এর জন্য detailed per-image results generate করে যার মধ্যে রয়েছে ground truth captions, predicted base captions, METEOR scores, detected emotions, এবং emotion-aware captions। Pipeline চারটি comprehensive CSV files output করে: evaluation_results.csv যাতে প্রতিটি test image-এর জন্য সব ছয়টি metrics রয়েছে, evaluation_summary.csv যা aggregate BLEU এবং METEOR scores প্রদান করে, results2.csv যাতে custom user-uploaded images-এর জন্য emotion-aware captions রয়েছে, এবং trained model checkpoint যা image_caption_model.pt হিসেবে saved হয় deployment এবং future use-এর জন্য।

Technical Implementation Highlights

Implementation PyTorch leverage করে deep learning operations-এর জন্য, Transformers library GPT-2 tokenization-এর জন্য, TIMM pretrained vision models-এর জন্য, DeepFace TensorFlow-Keras backend সহ emotion recognition-এর জন্য, NLTK linguistic processing-এর জন্য, এবং সব data process করে carefully constructed dataloaders-এর মাধ্যমে 2 worker processes সহ efficient parallel data loading-এর জন্য। Model architecture-এ approximately 86 million parameters আছে ViT encoder-এ এবং 45 million parameters GPT decoder-এ, মোট 131 million trainable parameters। Training GPU acceleration-এ execute হয় যখন available, সব 6 epochs সম্পন্ন হয় প্রায় 30-45 minutes-এ Tesla T4 GPU-তে। সম্পূর্ণ pipeline—raw images থেকে visual encoding, cross-attended caption generation, emotion detection, এবং grammatical enhancement পর্যন্ত—computer vision, natural language generation, এবং affective computing-এর সফল integration প্রদর্শন করে যা human-like, emotionally aware image descriptions তৈরি করে যা simple object recognition-এর বাইরে গিয়ে visual scenes-এর emotional tone এবং atmosphere capture করে।