🎤 উপস্থাপনা বক্তৃতা স্ক্রিপ্ট — বাংলা

ইমোশন-অ্যাওয়ার ইমেজ ক্যাপশন জেনারেটর

TeamML Newbies | ML Sessional Final Presentation

লক্ষ্য সময়: ~৮ মিনিট

▧ স্লাইড ১ — শিরোনাম (০:০০–০:২০)

> সুপ্রভাত / শুভ বিকাল স্যার/ম্যাম। আমি [আপনার নাম], TeamML Newbies-এর পক্ষ থেকে আজকের উপস্থাপনা দিচ্ছি। আমাদের প্রজেক্টের নাম— **Emotion-Aware Image Caption Generator**। আমাদের টিমের সদস্যরা হলেন: Anuron Maitro, Md. Asif Ali এবং Himadri Gobinda Biswas।

▧ স্লাইড ২ — ভূমিকা ও অনুপ্রেরণা (০:২০–১:১০)

> Image Captioning হলো একটি কম্পিউটার ভিশন টাস্ক, যেখানে একটি ছবির জন্য স্বয়ংক্রিয়ভাবে টেক্সট বর্ণনা তৈরি করা হয়। বিদ্যমান সিস্টেমগুলো বলতে পারে ছবিতে *কী* আছে — মানুষ, অ্যাকশন, বস্তু। কিন্তু একটি গুরুত্বপূর্ণ বিষয় একদমই মিস করে — ছবিতে থাকা মানুষটি *কেমন অনুভব করছে*।

> উদাহরণ হিসেবে ধরুন, একজন মানুষ সমুদ্র সৈকতে দাঁড়িয়ে আছেন। একটি সাধারণ সিস্টেম বলবে: "*A person standing on a beach.*" এটি তথ্যগতভাবে ঠিক, কিন্তু মানুষটি কি খুশি, দুঃখী নাকি উদ্বিগ্ন — তা বলে না।

> আমাদের অনুপ্রেরণা তিনটি জায়গা থেকে এসেছে। **প্রথমত**, অ্যাক্সেসিবিলিটি — দৃষ্টিপ্রতিবন্ধী ব্যবহারকারীরা আবেগময় বর্ণনা থেকে অনেক বেশি সুবিধা পান। **দ্বিতীয়ত**, Human-AI Interaction — AI যত মানবিক ও আবেগ-সচেতন হয়, তত কার্যকর হয়। **তৃতীয়ত**, স্বাস্থ্যসেবা ও সোশ্যাল মিডিয়ায় আবেগের প্রসঙ্গ অত্যন্ত গুরুত্বপূর্ণ।

> আমাদের উদ্ভাবন সহজ: একটি সাধারণ ক্যাপশনকে আমরা আবেগ যোগ করে সমৃদ্ধ করি। "*A person on a road*" হয়ে যায় "*A joyful person on a road*" — মানুষের আবেগ সনাক্ত করে সেটি গ্রামাটিক্যালি ক্যাপশনে বসিয়ে।

▧ স্লাইড ৩ — সমস্যা ও আমাদের পদ্ধতি (১:১০–১:৫০)

> মূল সমস্যাটি হলো: **কীভাবে এমন ক্যাপশন তৈরি করা যাবে যা ছবির ভিজুয়াল কন্টেন্ট এবং মানুষের আবেগ — দুটোই বর্ণনা করবে?**

> এটি তিনটি উপ-সমস্যায় বিভক্ত: একটি নির্ভুল বেস ক্যাপশন তৈরি করা, মুখের আবেগ নির্ভরযোগ্যভাবে সনাক্ত করা, এবং আবেগটি বাক্যে স্বাভাবিকভাবে সংযুক্ত করা।

> আমাদের সমাধান তিনটি কম্পোনেন্টে: **Vision Transformer + GPT-2** ক্যাপশন তৈরির জন্য, **DeepFace** আবেগ সনাক্তের জন্য, এবং **NLTK-এর POS Tagger** গ্রামাটিক্যাল ঢোকানোর জন্য।

▧ স্লাইড ৪ — সম্পূর্ণ সিস্টেম পাইপলাইন (১:৫০–২:৩০)

> এই ডায়াগ্রামটি আমাদের পুরো পাইপলাইন দেখাচ্ছে। আমি বামদিক থেকে শুরু করছি।

> ছবি আপলোড হলে **দুটো প্রক্রিয়া একসাথে** চলে। বাম দিকে: ছবিটি Vision Transformer Encoder-এ যায়, যেটি একটি ৫১২-ডায়মেনশনের ভেক্টর তৈরি করে। এই ভেক্টরটি GPT-2 Decoder-এ পাঠানো হয়, যেটি **বেস ক্যাপশন** তৈরি করে।

> ডান দিকে: একই ছবি DeepFace-এ পাঠানো হয়। যদি মুখ পাওয়া যায়, সে dominant আবেগ রিটার্ন করে। না পেলে, ডিফল্ট হিসেবে "neutral" ব্যবহার হয়।

> তারপর বেস ক্যাপশন এবং আবেগ — দুটো মিলে **NLTK Processor**-এ যায়। সেটি গ্রামাটিক্যালি আবেগ বিশেষণটি প্রথম noun-এর আগে বসিয়ে দেয়। চূড়ান্ত আউটপুট হলো **Emotion-Aware Caption**।

▧ স্লাইড ৫ — ViT এনকোডার আর্কিটেকচার (২:৩০–৩:২০)

> এখন প্রথম প্রধান কম্পোনেন্ট দেখি — **Vision Transformer Encoder**। এই ডায়াগ্রামটি দেখাচ্ছে কীভাবে ছবির তথ্য এনকোডারের মধ্য দিয়ে যায়।

> ইনপুট ছবির আকার হলো 224×224×3 (উচ্চতা×প্রস্থ×চ্যানেল)। এটি প্রথমে **196টি 16×16 প্যাচে** ভাগ হয়। প্রতিটি প্যাচ একটি সংখ্যাগত ভেক্টরে রূপান্তরিত হয়। এই ভেক্টরের ডায়মেনশন হলো 768 — কারণ $16^2 \times 3 = 768$। এটি একটি Convolutional Layer দিয়ে করা হয়।

> এরপর একটি বিশেষ **[CLS] Token** সামনে যোগ করা হয়, এবং সব 197টি টোকেনে **Positional Embedding** যোগ হয় — যাতে ট্রান্সফর্মার বুঝতে পারে কোন প্যাচ কোথায় ছিল।

> তারপর এগুলো **8টি Encoder Block**-এর মধ্য দিয়ে যায়। প্রতিটি ব্লকে আছে: **4 head-এর Multi-Head Self-Attention** — এটি দিয়ে মডেল ছবির বিভিন্ন অংশে একসাথে মনোযোগ দিতে পারে। তারপর আছে Feed-Forward MLP যা 768 থেকে 3072-এ বাড়িয়ে আবার 768-এ নামায়। সাথে Layer Normalization এবং Residual Connection।

> গুরুত্বপূর্ণ: আমরা `timm` লাইব্রেরির **vit_base_patch16_224** প্রি-ট্রেইনড মডেল ব্যবহার করেছি। শেষ ব্লকের [CLS] টোকেন পুরো ছবিকে 768-ডায়মেনশনে উপস্থাপন করে। এটি একটি **Linear Projection Layer** দিয়ে 512-ডায়মেনশনে নামানো হয় — কারণ GPT-2 ডিকোডারের hidden size 512।

▧ স্লাইড ৬ — GPT-2 ডিকোডার আর্কিটেকচার (৩:২০–৪:১০)

> দ্বিতীয় কম্পোনেন্ট হলো আমাদের কাস্টম **GPT-2 স্টাইল ডিকোডার**। এই ডায়াগ্রামটি দেখাচ্ছে কীভাবে ক্যাপশনের শব্দগুলো একে একে তৈরি হয়।

> ডিকোডার দুটো ইনপুট নেয়: ViT-এর **ইমেজ ফিচার** (512-ডায়মেনশন), এবং **আগের টোকেনগুলো** — [BOS] দিয়ে শুরু।

> প্রতিটি **8টি Decoder Block**-এ তিনটি অপারেশন আছে। প্রথম: **Causal Self-Attention** (8 head) — এটি masked, তাই প্রতিটি টোকেন শুধু আগের টোকেন দেখতে পায়। এটি autoregressive property নিশ্চিত করে। দ্বিতীয়: **Cross-Attention** — প্রতিটি ডিকোডার ব্লক ViT-এর ইমেজ ফিচারকে query করে। এভাবে প্রতিটি উৎপন্ন শব্দ ছবির সাথে সংযুক্ত থাকে। তৃতীয়: Feed-Forward MLP।

> 8টি ব্লকের পরে, 512-ডায়মেনশন আউটপুটকে 50,260 শব্দের vocabulary-তে map করা হয়। সবচেয়ে সম্ভাব্য পরবর্তী শব্দ বেছে নেওয়া হয় — এটিকে **Greedy Decoding** বলে। সেই শব্দটি আবার ইনপুট হিসেবে দেওয়া হয়, যতক্ষণ না [EOS] তৈরি হয় বা 50 টোকেনের সীমা শেষ হয়।

> ডায়াগ্রামে ড্যাশড লাল তীরটি এই **autoregressive loop** দেখাচ্ছে।

▧ স্লাইড ৭ — আবেগ সনাক্তকরণ (৪:১০–৪:৪০)

> আবেগ সনাক্তের জন্য আমরা **DeepFace** ব্যবহার করেছি — এটি একটি প্রি-ট্রেইনড ফেশিয়াল ইমোশন রিকগনিশন ফ্রেমওয়ার্ক, তাই আলাদা ট্রেনিংয়ের দরকার নেই। আমরা `enforce_detection=False` ব্যবহার করি, যাতে আংশিক বা কোণাচে মুখও handle হয়।

> DeepFace 7টি emotion category সনাক্ত করে: Happy, Sad, Angry, Surprise, Fear, Disgust, এবং Neutral। এটি প্রতিটি ক্যাটাগরির জন্য probability দেয় এবং আমরা **dominant emotion** নিই।

> যদি মুখ একেবারে ধরা না পড়ে, তবে ডিফল্টে "neutral" ব্যবহার হয় — পাইপলাইন সবসময় একটি আউটপুট দেয়।

▧ স্লাইড ৮ — NLTK সংযোজন (৪:৪০–৫:১০)

> তৃতীয় কম্পোনেন্ট হলো NLTK-ভিত্তিক **গ্রামাটিক্যাল ইনসার্শন অ্যালগরিদম**।

> প্রথমে বেস ক্যাপশনকে Tokenize করা হয়। তারপর **Part-of-Speech Tagging** দিয়ে প্রতিটি শব্দের ব্যাকরণগত ভূমিকা চিহ্নিত করা হয়। তারপর বাক্যের প্রথম **Noun** খোঁজা হয় — যেকোনো NN, NNS, NNP বা NNPS ট্যাগ। সেই Noun-এর ঠিক আগে emotion বিশেষণটি বসানো হয়।

> উদাহরণ: "*a person standing on a road*", emotion: happy। POS tagging দেখায় "person" হলো প্রথম noun। তাই "joyful" বসে তার আগে। ফলাফল: "*a joyful person standing on a road*" /

> আবেগ-বিশেষণ ম্যাপিং: happy→joyful, sad→melancholic, angry→angry, surprise→surprised, fear→fearful, disgust→disgusted, neutral→calm।

▧ স্লাইড ৯ — ডেটাসেট (৫:১০–৫:৩০)

> আমরা **Flickr30k ডেটাসেট** ব্যবহার করেছি — মোট 8,091 ছবি, প্রতিটিতে 5টি করে ক্যাপশন। Deduplication করে প্রতি ছবির একটি ক্যাপশন রেখে, আমরা 80/20 অনুপাতে split করেছি — প্রায় 6,473 ছবি training-এ এবং 1,618 ছবি test-এ। সব ছবি 224×224-এ resize করা হয়েছে এবং ImageNet-এর mean ও standard deviation দিয়ে normalize করা হয়েছে।

▧ স্লাইড ১০ — ট্রেনিং কনফিগারেশন (৫:৩০–৬:০০)

> মোট **20 epoch** ট্রেনিং করা হয়েছে। প্রথম 2 epoch-এ ViT encoder **frozen** রাখা হয় — শুধু GPT-2 decoder এবং 768→512 projection layer train হয়। এটি প্রথম দিকের training কে স্থিতিশীল করে।

> Epoch 3 থেকে 20 পর্যন্ত সব weights unfreeze করে পুরো মডেল end-to-end train করা হয়। Learning rate **2×10^{-4}**, batch size **16**, optimizer হলো **Adam** এবং weight decay 10^{-6}। Dropout 0.5 সব জায়গায় প্রয়োগ হয়। Training হয়েছে Kaggle-এর **NVIDIA Tesla T4 GPU**-তে, মোট সময় প্রায় ৬ থেকে ৮ ঘণ্টা।

▧ স্লাইড ১১ — ফলাফল (৬:০০–৬:৪০)

> এখন quantitative results দেখি। প্রায় 1,618 ছবির test set-এ (শুধু বেস ক্যাপশনের উপর): BLEU-1: 33.04%, BLEU-2: 16.23%, BLEU-3: 9.13%, BLEU-4: 5.28%, এবং METEOR: 22.59%।

> Reference paper-এর (Sankhla et al., IEEE 2024) সাথে তুলনায় আমাদের BLEU score কম। এর কারণ reference paper সম্পূর্ণ প্রি-ট্রেইনড pipeline ব্যবহার করেছে এবং আরও বেশি resource ছিল। কিন্তু METEOR score-এ আমরা তাদের 24.83%-এর তুলনায় 22.59% পেয়েছি — যা যুক্তিসঙ্গতভাবে কাছাকাছি। Qualitatively, emotion ইন্টিগ্রেশন grammatically সঠিক এবং অর্থবহ।

▧ স্লাইড ১২ ও ১৩ — Qualitative ফলাফল (৬:৪০–৭:১০)

> এখানে কিছু নমুনা আউটপুট দেখা যাচ্ছে। Happy emotion-এর ক্ষেত্রে: বেস ক্যাপশন "*Two children playing in a park*" → "*Two joyful children playing in a park*" / Sad emotion-এ: "*A person sitting alone on a bench*" → "*A melancholic person sitting alone on a bench*" /

> Angry emotion-এ পাই "*An angry person with crossed arms*", এবং Neutral emotion-এ পাই "*A calm businessman in an office*" / প্রতিটি ক্ষেত্রেই বিশেষণটি প্রথম noun-এর আগে grammatically সঠিকভাবে বসেছে।

▧ স্লাইড ১৪ — Deployment (৭:১০–৭:৩০)

> পুরো সিস্টেমটি আমরা real web application হিসেবে deploy করেছি। Backend হলো FastAPI server — HuggingFace Spaces-এ Docker container-এ চলছে। Frontend হলো React অ্যাপ — Vercel-এ হোস্ট। Model (1.91 GB) আলাদা HuggingFace Models Hub-এ রাখা হয়েছে কারণ Spaces-এর সীমা মাত্র 1 GB — এবং startup-এ dynamically download হয়। সম্পূর্ণ deployment খরচ শূন্য টাকা।

▧ স্লাইড ১৫ ও ১৬ — সীমাবদ্ধতা ও উপসংহার (৭:৩০–৮:০০)

> কিছু সীমাবদ্ধতা আছে: plural noun-এর ক্ষেত্রে grammar সামান্য awkward হতে পারে, শুধু dominant emotion ধরা হয়, এবং বিশেষণের semantic fit সবসময় নিখুঁত না।

> উপসংহারে: আমরা সফলভাবে একটি সম্পূর্ণ 3-ধাপের pipeline তৈরি করেছি — ViT, GPT-2, DeepFace এবং NLTK একত্রে ব্যবহার করে। Flickr30k-এ METEOR score 22.59% অর্জন করেছি এবং একটি live ওয়েব অ্যাপ deploy করেছি। এটি প্রমাণ করে যে emotionally-aware image description প্রি-ট্রেইনড মডেল ও হালকা NLP rule-এর মাধ্যমে বাস্তবে সম্ভব।

> আপনাদের অনেক ধন্যবাদ। কোনো প্রশ্ন থাকলে জানাবেন।

[বাংলা বক্তৃতা স্ক্রিপ্ট শেষ — আনুমানিক ~ ৮ মিনিট]